

INTELLIGENZA ARTIFICIALE GENERATIVA

COME FUNZIONANO LE RETI NEURALI E COME VENGONO ADDESTRATE

Fonti:

- *Rohit Patel, Towards Data Science, Understanding LLMs from Scratch Using Middle School Math*
- *Eleonora Misino, Zanichelli, Dentro l'IA: come imparano le reti neurali*

“Qualunque tecnologia sufficientemente avanzata è indistinguibile dalla magia.”

Curiosità

Tre leggi di Clarke

RETI NEURALI

DEFINIZIONE

Una rete neurale artificiale (**NN**) è un modello computazionale ispirato alla struttura e al funzionamento del cervello umano. È composta da unità chiamate **neuroni artificiali** organizzati in strati, che possono prendere in input dei numeri e possono emettere in output altri numeri.

Il **Deep learning** è un sottoinsieme del **Machine Learning (ML)** basato su livelli di reti neurali e sta alla base dell'intelligenza artificiale generativa.

Curiosità

il Mark I Perceptron del 1958

ESEMPIO: CLASSIFICARE UN NUMERO

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



Figura 1: creata con [Canva](#)

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)

**MATRICE
20 x 20 PIXEL**




Figura 1: creata con [Canva](#)

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




Figura 1: creata con Canva

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)

	0
	0.5




Figura 1: creata con Canva

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




Figura 1: creata con Canva

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)

	0
	0.5
	0.8
	1

0	0	0	0	0	0.5	0.5	0.5	0.8	0.8	0.8	0.8	0.5	0.5	0	0	0	0	0	0
0	0	0	0	0.5	0.5	0.8	0.8	1	1	1	1	0.8	0.5	0.5	0	0	0	0	0
0	0	0	0.5	0.5	0.8	0.8	1	1	1	1	1	1	0.8	0.8	0	0	0	0	0
0	0	0.5	0.5	0.8	0.8	1	1	1	1	1	1	1	1	0.8	0.8	0	0	0	0
0	0	0.5	0.5	0.8	0.8	1	1	0.5	0	0.5	0.5	1	1	1	0.8	0.5	0	0	0
0	0	0.5	0.5	0.8	1	1	0.5	0.5	0	0	0.5	0.5	1	1	0.8	0.5	0	0	0
0	0	0	0.5	0.5	1	1	0.5	0.5	0	0	0	0.5	1	1	0.8	0.5	0	0	0
0	0	0	0	0.5	0.8	1	1	0	0	0	0	0	1	1	0.5	0.5	0	0	0
0	0	0	0	0.5	0.5	0.8	1	1	0.5	0.5	0	1	1	0.8	0.5	0	0	0	0
0	0	0	0	0	0.5	0.8	1	1	1	1	1	1	0.8	0.8	0.5	0	0	0	0
0	0	0	0	0	0	0.8	0.8	1	1	1	1	1	0.8	0.5	0.5	0	0	0	0
0	0	0	0	0.5	0.5	0.8	0.8	1	1	1	1	1	0.8	0.5	0.5	0	0	0	0
0	0	0	0	0.5	0.8	0.8	1	1	0.8	0.8	1	1	0.8	0.8	0	0	0	0	0
0	0	0	0	0.5	0.8	1	1	0.8	0.8	0.8	0	1	1	1	0.8	0	0	0	0
0	0	0	0.5	0.5	1	1	1	0.8	0	0	0	0.5	1	1	0.8	0	0	0	0
0	0	0	0.5	0.8	0.8	1	1	0	0	0	0.5	0.5	1	1	0.8	0	0	0	0
0	0	0	0	0	0.8	1	1	1	0.5	0.5	0.5	0.5	1	1	0.8	0.5	0	0	0
0	0	0	0	0.5	0.5	0.8	1	1	1	1	1	1	1	0.8	0.5	0.5	0	0	0
0	0	0	0	0	0.5	0.5	0.8	1	1	1	1	1	0.8	0.5	0.5	0	0	0	0
0	0	0	0	0	0	0.5	0.5	0.8	0.8	0.8	0.8	0.8	0.5	0.5	0	0	0	0	0

Figura 1: creata con Canva

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)





Figura 1: creata con [Canva](#)

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)

CODIFICA

0	0	0	0	0	0.5	0.5	0.5	0.8	0.8	0.8	0.8	0.5	0.5	0	0	0	0	0	0
0	0	0	0	0.5	0.5	0.8	0.8	1	1	1	1	0.8	0.5	0.5	0	0	0	0	0
0	0	0	0.5	0.5	0.8	0.8	1	1	1	1	1	1	0.8	0.8	0	0	0	0	0
0	0	0.5	0.5	0.8	0.8	1	1	1	1	1	1	1	1	0.8	0.8	0	0	0	0
0	0	0.5	0.5	0.8	0.8	1	1	0.5	0	0.5	0.5	1	1	1	0.8	0.5	0	0	0
0	0	0.5	0.5	0.8	1	1	0.5	0.5	0	0	0.5	0.5	1	1	0.8	0.5	0	0	0
0	0	0	0.5	0.5	1	1	0.5	0.5	0	0	0	0.5	1	1	0.8	0.5	0	0	0
0	0	0	0	0.5	0.8	1	1	0	0	0	0	0	1	1	0.5	0.5	0	0	0
0	0	0	0	0.5	0.5	0.8	1	1	0.5	0.5	0	1	1	1	0.8	0.5	0	0	0
0	0	0	0	0	0.5	0.8	1	1	1	1	1	1	1	0.8	0.8	0.5	0	0	0
0	0	0	0	0	0	0.8	0.8	1	1	1	1	1	1	0.8	0.5	0.5	0	0	0
0	0	0	0	0.5	0.5	0.8	0.8	1	1	1	1	1	1	0.8	0.5	0.5	0	0	0
0	0	0	0	0.5	0.8	0.8	1	1	0.8	0.8	1	1	1	1	0.8	0.8	0	0	0
0	0	0	0	0.5	0.8	1	1	0.8	0.8	0.8	0	1	1	1	1	0.8	0	0	0
0	0	0	0.5	0.5	1	1	1	0.8	0	0	0	0.5	1	1	0.8	0	0	0	0
0	0	0	0.5	0.8	0.8	1	1	0	0	0	0.5	0.5	1	1	0.8	0	0	0	0
0	0	0	0	0	0.8	1	1	1	0.5	0.5	0.5	0.5	1	1	0.8	0.5	0	0	0
0	0	0	0	0.5	0.5	0.8	1	1	1	1	1	1	1	1	0.8	0.5	0.5	0	0
0	0	0	0	0	0.5	0.5	0.8	1	1	1	1	1	1	0.8	0.5	0.5	0	0	0
0	0	0	0	0	0	0.5	0.5	0.8	0.8	0.8	0.8	0.8	0.5	0.5	0	0	0	0	0


ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



20 x 20 PIXEL

- ☐ 0
- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☐ 5
- ☐ 6
- ☐ 7
- ☐ 8
- ☐ 9

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




20 x 20 PIXEL

NEURONE




- ☐ 0
- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☐ 5
- ☐ 6
- ☐ 7
- ☐ 8
- ☐ 9

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




20 x 20 PIXEL

NEURONE




- ☐ 0
- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☐ 5
- ☐ 6
- ☐ 7
- ☐ 8
- ☐ 9

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




20 x 20 PIXEL




- ☐ 0
- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☐ 5
- ☐ 6
- ☐ 7
- ☐ 8
- ☐ 9

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




20 x 20 PIXEL




- ☐ 0
- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☐ 5
- ☐ 6
- ☐ 7
- ☐ 8
- ☐ 9

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



20 x 20 PIXEL


NEURONE



$$(0.5 \times 0.1) + (0.8 \times 0.3) = 0.05 + 0.24 = 0.29$$


- ☐ 0
- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☐ 5
- ☐ 6
- ☐ 7
- ☐ 8
- ☐ 9

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




- 0
- 1
- 2
- 3
- 4
- 5
- 6
- 7
- 8
- 9


ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



ESEMPIO: CLASSIFICARE UN NUMERO (0-9)

INTELLIGENZA?!

Il modello **non ha idea** di cosa sia il disegno di un otto o cosa siano i 400 dati forniti in ingresso. Il modello ha semplicemente il compito di prendere esattamente 400 numeri e restituire esattamente 10 numeri (0-9).

L'INTERPRETAZIONE DEI DATI IN INPUT E OUTPUT SPETTA A NOI.

COME SI DETERMINANO I PESI?

ADDESTRARE IL MODELLO

COME SI DETERMINANO I PESI?

TRAINING DATA

Per poter addestrare il modello e quindi determinare i pesi associati alle connessioni tra i neuroni, è necessario fornire al modello un insieme di dati di addestramento (**training data**), i quali contengono esempi di input e i corrispondenti output desiderati.

I dati vengono quindi **etichettati** in modo che il modello possa apprendere la relazione tra input e output.

Nell'esempio precedente i dati di addestramento etichettati potrebbero essere:

- Input: [0, 0, 0, 0.5, 0.8, 1, 1, (ecc...)] → Output desiderato: 8;
- Input: [0, 0, 0, 0.8, 1, 1, 0.5, (ecc...)] → Output desiderato: 3.

ALLENAMENTO DEL MODELLO


Data la perdita, l'algoritmo di apprendimento utilizza un metodo chiamato **discesa del gradiente** per aggiornare i pesi della rete neurale. L'obiettivo è minimizzare la perdita, ovvero ridurre la differenza tra l'output ottenuto e l'output desiderato.

Questo processo viene ripetuto per **molte iterazioni**, utilizzando diversi esempi di dati di addestramento (**epoche**), fino a quando la rete neurale non raggiunge un livello accettabile di accuratezza.

In pratica, allenare le reti profonde è un processo lungo e complesso perché i gradienti possono facilmente sfuggire al controllo, andando a zero o all'infinito durante l'allenamento. Con modelli moderni contenenti miliardi di parametri e funzioni molto più complesse, l'addestramento di un modello richiede enormi risorse di calcolo.

Curiosità

Hugging Face: [modelli di AI open source](#)



INTELLIGENZA ARTIFICIALE GENERATIVA

PRINCIPALI RISCHI E PROBLEMI

Fonti:

- *ANSA, BBC, Corriere della Sera, Forbes Italia, Il Post, Il Sole 24 Ore, La Repubblica, Rai News*
- *Agenda Digitale, CorCom, DDAY.it, Geopop, Hardware Upgrade, Punto Informatico, TechCrunch, Tech Princess, Technology.org, TechRadar, Tom's Hardware, Wired Italia*
- *Facta, Valori.it*
- *16x Prompt, Digital Innovation Days, Il Disinformatico, Pluralistic, Reality Check, Siamomine*
- *IRPA, MIT Impact Bench, Privacy Network, Wikipedia*
- *GitHub, Lovense, OpenAI, YouTube*

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

BIAS NEI DATI DI ADDESTRAMENTO

DEFINIZIONE

I **bias algoritmici** dell'AI sono preferenze sistematiche o discriminazioni strutturali che emergono nei **dati con cui l'AI è addestrata**. I modelli di AI imparano individuando pattern e regolarità nei dati: **se questi dati contengono pregiudizi verso una specifica categoria, l'algoritmo li apprende e li riproduce, amplificandoli.**

Approfondimento

Bias cognitivi e bias dell'AI

L'Ai è ancora addestrata con dati pieni di razzismo e sessismo

Le informazioni usate per sviluppare i sistemi di intelligenza artificiale sono infarcite di pregiudizi, che poi vengono distribuiti in tutto il mondo

All'intelligenza artificiale di Amazon non piacciono le donne scartati i cv femminili

ANTI-FRODE ED ETICA DELL'AI

L'algoritmo dei sussidi sociali discrimina e fa cadere il governo: il caso olandese

L'intelligenza artificiale non è neutrale: può imparare i pregiudizi della nostra società

Vent'anni fa, *Minority Report* aveva già capito perché la polizia predittiva avrebbe fallito

Riconoscimento facciale. Secondo uno studio la polizia del Regno Unito non rispetta gli standard minimi etici e legali.

Figura 5: Immagine creata utilizzando screenshots tratti dai seguenti articoli: [CorCom](#), [Wired](#), [Agenda Digitale](#), [IRPA](#), [Geopop](#), [Wired](#)

ALLUCINAZIONI

DEFINIZIONE

Le **allucinazioni** (dette anche confabulazioni) generate dai modelli linguistici **sono affermazioni plausibili ma false. Alcune risposte appaiono verosimili e convincenti, ma in realtà contengono informazioni errate o inventate.** Il termine deriva da una vaga analogia con le allucinazioni umane, derivate normalmente da false percezioni. Le allucinazioni dell'intelligenza artificiale tuttavia, al contrario di quelle umane, derivano da risposte costruite in modo errato, e non da un'errata percezione.

Approfondimento

Dichiarazioni di OpenAI sulle allucinazioni

Podcast RSI - Story: Perché le Tesla vedono i fantasmi?

IL PROVVEDIMENTO

Avvocato usa l'AI e cita quattro sentenze inventate, il giudice lo condanna: «Colpa grave non verificare le fonti»

ChatGpt ha un problema di diffamazione

Ha accusato un professore di diritto di un'università statunitense di molestie e un sindaco australiano di corruzione. Ma in entrambi i casi, si è inventato di sana pianta tutto

McDonald's abbandona l'intelligenza artificiale dopo gli errori comici, dal bacon sul gelato alle 260 scatole di Nuggets

Una telecamera la manda in carcere per 13 giorni: era innocente

Una donna trascorre 13 giorni in carcere dopo che una telecamera Flock ha segnalato il suo SUV vicino a un incidente mortale in Florida con tre vittime.

ChatGPT 4o



How many R's are in the word strawberry

here are two "R"s in the word "strawberry."



Colla sulla pizza: Google rimuove manualmente le risposte imbarazzanti di AI Overview

Figura 6: Immagine creata utilizzando screenshots tratti dai seguenti articoli: [Il Disinformatico](#), [16x Prompt](#), [Wired](#), [Corriere della Sera](#), [Hardware Upgrade](#), [Tom's Hardware](#), [Corriere della Sera](#)




Figura 7: Screenshot di una conversazione con ChatGpt utilizzando un'immagine scattata al bar per il trentesimo compleanno di Mapo.

MANIPOLAZIONE E DISINFORMAZIONE

DEFINIZIONE

Utilizzando l'intelligenza artificiale generativa è possibile creare contenuti verosimili e/o ingannevoli, come immagini, video, audio e testi, che possono essere utilizzati per manipolare l'opinione pubblica o diffondere disinformazione.

Approfondimento

ANSA: Le manipolazioni hanno finalità politica per il 24,6% dei casi

Google's AI Answers Are Wrong Millions of Times Per Hour —
And Most People Have No Idea

Posted April 8, 2026

L'intelligenza artificiale generativa segna l'inizio di una
nuova era per la disinformazione

La polizia ha diffuso una foto degli scontri di Torino alterata
con l'IA, scatenando una vera e propria teoria del complotto

L'immagine è stata poi utilizzata sui social media per accusare l'agente aggredito di mentire

**Gli assistenti IA sono imprecisi nel dare le
notizie: il 45% delle risposte contiene
errori gravi. Lo studio della BBC**

I hacked ChatGPT and Google's AI - and
it only took 20 minutes

Figura 8: Immagine creata utilizzando screenshots tratti dai seguenti articoli: [Facta](#), [Dday.it](#), [Facta](#), [BBC](#), [Technology.org](#)

REALITY CHECK

Quiz: reale o generata artificialmente?

AI SLOP E ENSHITTIFICATION

l'**AI slop** (Sbobba) è un termine utilizzato per descrivere il fenomeno della **bas-sa qualità dei contenuti generati dall'intelligenza artificiale**, che si manifesta in particolare nei social media e nelle piattaforme di condivisione di contenuti, in quanto alle piattaforme non interessa la qualità dei contenuti, ma solo la quantità e l'engagement.

Il rischio è che l'AI slop possa portare a un **totale enshittification** delle piattaforme, con conseguenze negative per gli utenti e per la società in generale.

Approfondimento

Wired: [Andrea Daniele Signorelli - AI slop](#)

Cory Doctorow - [TikTok's enshittification](#)

PRIVACY E SICUREZZA INFORMATICA

DEFINIZIONE

Ogni **input** inserito in un chatbot può diventare parte di un'enorme **banca dati**, usata per addestrare altri modelli o **esposta**, in casi estremi, a fughe di dati o accessi non autorizzati. Ecco perché è essenziale porsi delle domande: cosa succede a ciò che scriviamo? Chi può leggerlo? Come possiamo proteggerci?

Approfondimento

Strategie pratiche per la privacy nei chatbot

**Claude usato per sviluppare armi,
sorveglianza e truffe**

**La pubblicità di ChatGPT sarà influenzata dalle nostre conversazioni
con il chatbot**

**Il clamoroso
fallimento di Builder,
la startup che invece
di un'AI aveva 700
programmatore
indiani**

Segnalazione a Character AI

Questo servizio permette agli utenti di creare dei bot ispirati a personaggi, reali o di fantasia, con i quali è possibile intrattenere conversazioni...

Cina, una scuola misura l'attenzione degli studenti con il riconoscimento facciale

Il docente riceve in tempo reale i risultati del monitoraggio delle espressioni degli studenti, per capire se sono attenti e se apprezzano la lezione: l'ultima frontiera del Grande Fratello cinese

Figura 9: Immagine creata utilizzando screenshots tratti dai seguenti articoli: [Punto Informatico](#), [Privacy Network](#), [Wired](#), [La Repubblica](#), [Tech Princess](#).

ETICHETTATORI E SFRUTTAMENTO LAVORATIVO

DEFINIZIONE

L'**etichettatura** dei dati richiede l'identificazione dei dati non elaborati (ad esempio immagini, file di testo, video) e quindi l'**aggiunta di una o più etichette a tali dati per specificarne il contesto** per i modelli, consentendo al modello di machine learning di fare previsioni accurate.

Approfondimento

Documentario: [In the Belly of AI](#)

Podcast RSI - Dietro le IA c'è manodopera africana sfruttata

Why Big Tech pays poor Kenyans to teach self-driving cars

Captcha if you can: how you've been training AI for years without realising it

Dietro ChatGPT c'è un esercito di addestratori sottopagati

Un'inchiesta di *Time* ha svelato che OpenAI ha affidato a un fornitore esterno il compito di visionare ed etichettare contenuti violenti per ripulire i risultati dell'algoritmo

Il lato oscuro di ChatGPT: lavoratori pagati meno di 2 dollari l'ora ed esposti alle peggiori nefandezze di Internet

Meta registra movimenti del mouse e tasti premuti dai dipendenti «per addestrare l'IA»

Gli «etichettatori», ovvero i nuovi schiavi dell'intelligenza artificiale

Figura 10: Immagine creata utilizzando screenshots tratti dai seguenti articoli: [BBC](#), [Forbes](#), [Wired](#), [TechCrunch](#), [TechRadar](#), [Dday.it](#), [Il Disinformatico](#), [Il Sole 24 Ore](#)

DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE

DEFINIZIONE

Il **diritto d'autore** è una branca del diritto privato, che ha lo scopo di **tutelare i frutti dell'attività intellettuale di carattere creativo** (ovvero le opere devono essere nuove e originali), attraverso il riconoscimento all'autore originario (o agli autori in caso di collaborazione creativa) dell'opera di una serie di diritti di carattere sia morale, sia patrimoniale.

Approfondimento

Il diritto d'autore

Le AI hanno un grosso problema con i dati e con i copyright: cosa sta succedendo

Per allenare i suoi chatbot Anthropic ha distrutto milioni di libri

Meta sotto accusa: avrebbe usato contenuti pirata ottenuti via Torrent per allenare l'IA

DIRITTO D'AUTORE

AI e copyright, la soluzione è nelle licenze esclusive

Pokémon Go utilizzato per addestrare i droni militari? Cosa è emerso sui dati Niantic

Figura 11: Immagine creata utilizzando screenshots tratti dai seguenti articoli: [Geopop](#), [Hardware Upgrade](#), [Agenda Digitale](#), [Hardware Upgrade](#), [Il Post](#).

SALUTE MENTALE E EFFETTI PSICOLOGICI

DEFINIZIONE

L'uso eccessivo o inappropriato dell'intelligenza artificiale generativa può avere effetti negativi sulla salute mentale e sul benessere psicologico degli individui. L'interazione con chatbot o assistenti virtuali può portare a dipendenza, isolamento sociale, ansia, depressione, disturbi del sonno e altri problemi psicologici.

Approfondimento

MIT Impact Bench: AI and Mental Health

La nuova economia della solitudine

Il bisogno di ascolto in una società sempre più sola e frammentata può essere colmato dalle AI Personas?



INTELLIGENZA ARTIFICIALE

L'ascesa dei virtual influencer: cosa ci dicono sul concetto di umanità

INTELLIGENZA ASSUEFATTIVA

Algoritmi compiacenti e dipendenza emotiva: i rischi delle IA "mimetiche"

Innamorato di un chatbot, un adolescente americano si è suicidato a 14 anni. La madre fa causa all'app: «Pericolosa e non testata»

Un Gesù virtuale sta confessando i fedeli in Svizzera

Riapre Way of the Future, la chiesa che venera gli algoritmi

DIGITAL AFTERLIFE: CONTINUARE A VIVERE OLTRE LA MORTE

Serie TV: verso il futuro (episodio 7)

Figura 12: Immagine creata utilizzando screenshots tratti dai seguenti articoli: [Siamomine](#), [Agenda Digitale](#), [Wired](#), [Corriere della Sera](#), [Ansa](#), [Digital Innovation Days](#), [Agenda Digitale](#), [Lovense: interactive AI robot sex doll](#)

IMPATTO AMBIENTALE E SOSTENIBILITÀ

DEFINIZIONE

L'addestramento e l'utilizzo di modelli di intelligenza artificiale generativa richiedono **grandi quantità di energia e risorse computazionali**, che possono avere un impatto significativo sull'ambiente. L'uso intensivo di data center e server per l'elaborazione dei dati può contribuire all'aumento delle emissioni di gas serra e al consumo di risorse naturali.



Figura 13: Approfondimento [Rai News: L'impatto ambientale dell'AI](#)

ARMI AUTONOME

DEFINIZIONE

Le **armi autonome** sono sistemi d'arma che, una volta attivati, possono **selezionare e ingaggiare obiettivi senza intervento umano**. L'uso di intelligenza artificiale generativa in ambito militare solleva questioni etiche e legali, in quanto le decisioni cruciali vengono prese da algoritmi, senza la supervisione umana diretta. Ciò può portare a conseguenze imprevedibili e potenzialmente pericolose, sollevando dibattiti sulla responsabilità e la regolamentazione di tali tecnologie.

Approfondimento

NAZA: Sistemi IA israeliani per uccidere palestinesi



Figura 14: Immagine di copertina del dossier di Valori.it: **L'intelligenza artificiale va al fronte**