

INTELLIGENZA ARTIFICIALE GENERATIVA

COME FUNZIONANO LE RETI NEURALI E COME VENGONO ADDESTRATE

Fonti:

- *Rohit Patel, Towards Data Science, Understanding LLMs from Scratch Using Middle School Math*
- *Eleonora Misino, Zanichelli, Dentro l'IA: come imparano le reti neurali*

“Qualunque tecnologia sufficientemente avanzata è indistinguibile dalla magia.”

Curiosità

Tre leggi di Clarke

RETI NEURALI

DEFINIZIONE

Una rete neurale artificiale (**NN**) è un modello computazionale ispirato alla struttura e al funzionamento del cervello umano. È composta da unità chiamate **neuroni artificiali** organizzati in strati, che possono prendere in input dei numeri e possono emettere in output altri numeri.

Il **Deep learning** è un sottoinsieme del **Machine Learning (ML)** basato su livelli di reti neurali e sta alla base dell'intelligenza artificiale generativa.

Curiosità

il Mark I Perceptron del 1958

ESEMPIO: CLASSIFICARE UN NUMERO

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



Figura 1: creata con [Canva](#)

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)

MATRICE
20 x 20 PIXEL




Figura 1: creata con [Canva](#)

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




Figura 1: creata con Canva

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)

	0
	0.5




Figura 1: creata con Canva

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)

	0
	0.5
	0.8




Figura 1: creata con Canva

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)

	0
	0.5
	0.8
	1




Figura 1: creata con Canva

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)





Figura 1: creata con [Canva](#)

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)

CODIFICA

0	0	0	0	0	0.5	0.5	0.5	0.8	0.8	0.8	0.8	0.5	0.5	0	0	0	0	0	0
0	0	0	0	0.5	0.5	0.8	0.8	1	1	1	1	0.8	0.5	0.5	0	0	0	0	0
0	0	0	0.5	0.5	0.8	0.8	1	1	1	1	1	1	0.8	0.8	0	0	0	0	0
0	0	0.5	0.5	0.8	0.8	1	1	1	1	1	1	1	1	0.8	0.8	0	0	0	0
0	0	0.5	0.5	0.8	0.8	1	1	0.5	0	0.5	0.5	1	1	1	0.8	0.5	0	0	0
0	0	0.5	0.5	0.8	1	1	0.5	0.5	0	0	0.5	0.5	1	1	0.8	0.5	0	0	0
0	0	0	0.5	0.5	1	1	0.5	0.5	0	0	0	0.5	1	1	0.8	0.5	0	0	0
0	0	0	0	0.5	0.8	1	1	0	0	0	0	0	1	1	0.5	0.5	0	0	0
0	0	0	0	0.5	0.5	0.8	1	1	0.5	0.5	0	1	1	1	0.8	0.5	0	0	0
0	0	0	0	0	0.5	0.8	1	1	1	1	1	1	1	0.8	0.8	0.5	0	0	0
0	0	0	0	0	0	0.8	0.8	1	1	1	1	1	1	0.8	0.5	0.5	0	0	0
0	0	0	0	0.5	0.5	0.8	0.8	1	1	1	1	1	1	0.8	0.5	0.5	0	0	0
0	0	0	0	0.5	0.8	0.8	1	1	0.8	0.8	1	1	1	1	0.8	0.8	0	0	0
0	0	0	0	0.5	0.8	1	1	0.8	0.8	0.8	0	1	1	1	1	0.8	0	0	0
0	0	0	0.5	0.5	1	1	1	0.8	0	0	0	0.5	1	1	0.8	0	0	0	0
0	0	0	0.5	0.8	0.8	1	1	0	0	0	0.5	0.5	1	1	0.8	0	0	0	0
0	0	0	0	0	0.8	1	1	1	0.5	0.5	0.5	0.5	1	1	0.8	0.5	0	0	0
0	0	0	0	0.5	0.5	0.8	1	1	1	1	1	1	1	1	0.8	0.5	0.5	0	0
0	0	0	0	0	0.5	0.5	0.8	1	1	1	1	1	1	0.8	0.5	0.5	0	0	0
0	0	0	0	0	0	0.5	0.5	0.8	0.8	0.8	0.8	0.8	0.5	0.5	0	0	0	0	0


ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



20 x 20 PIXEL

- ☐ 0
- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☐ 5
- ☐ 6
- ☐ 7
- ☐ 8
- ☐ 9

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




20 x 20 PIXEL

NEURONE




- ☐ 0
- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☐ 5
- ☐ 6
- ☐ 7
- ☐ 8
- ☐ 9

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




20 x 20 PIXEL

NEURONE




- ☐ 0
- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☐ 5
- ☐ 6
- ☐ 7
- ☐ 8
- ☐ 9

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




20 x 20 PIXEL




- ☐ 0
- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☐ 5
- ☐ 6
- ☐ 7
- ☐ 8
- ☐ 9

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




20 x 20 PIXEL

NEURONE




- ☐ 0
- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☐ 5
- ☐ 6
- ☐ 7
- ☐ 8
- ☐ 9

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



20 x 20 PIXEL


NEURONE



$$(0.5 \times 0.1) + (0.8 \times 0.3) = 0.05 + 0.24 = 0.29$$


- ☐ 0
- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☐ 5
- ☐ 6
- ☐ 7
- ☐ 8
- ☐ 9

ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




○ 0
○ 1
○ 2
○ 3
○ 4
○ 5
○ 6
○ 7
○ 8
○ 9


ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)




ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



ESEMPIO: CLASSIFICARE UN NUMERO (0-9)






Figura 3: creata con [Canva](#)


ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



ESEMPIO: CLASSIFICARE UN NUMERO (0-9)



ESEMPIO: CLASSIFICARE UN NUMERO (0-9)

INTELLIGENZA?!

Il modello **non ha idea** di cosa sia il disegno di un otto o cosa siano i 400 dati forniti in ingresso. Il modello ha semplicemente il compito di prendere esattamente 400 numeri e restituire esattamente 10 numeri (0-9).

L'INTERPRETAZIONE DEI DATI IN INPUT E OUTPUT SPETTA A NOI.

**COME SI DETERMINANO I PESI?
ADDESTRARE IL MODELLO**

COME SI DETERMINANO I PESI?

TRAINING DATA

Per poter addestrare il modello e quindi determinare i pesi associati alle connessioni tra i neuroni, è necessario fornire al modello un insieme di dati di addestramento (**training data**), i quali contengono esempi di input e i corrispondenti output desiderati.

I dati vengono quindi **etichettati** in modo che il modello possa apprendere la relazione tra input e output.

Nell'esempio precedente i dati di addestramento etichettati potrebbero essere:

- Input: [0, 0, 0, 0.5, 0.8, 1, 1, (ecc...)] → Output desiderato: 8;
- Input: [0, 0, 0, 0.8, 1, 1, 0.5, (ecc...)] → Output desiderato: 3.

ALLENAMENTO DEL MODELLO


Data la perdita, l'algoritmo di apprendimento utilizza un metodo chiamato **discesa del gradiente** per aggiornare i pesi della rete neurale. L'obiettivo è minimizzare la perdita, ovvero ridurre la differenza tra l'output ottenuto e l'output desiderato.

Questo processo viene ripetuto per **molte iterazioni**, utilizzando diversi esempi di dati di addestramento (**epoche**), fino a quando la rete neurale non raggiunge un livello accettabile di accuratezza.

In pratica, allenare le reti profonde è un processo lungo e complesso perché i gradienti possono facilmente sfuggire al controllo, andando a zero o all'infinito durante l'allenamento. Con modelli moderni contenenti miliardi di parametri e funzioni molto più complesse, l'addestramento di un modello richiede enormi risorse di calcolo.

Curiosità

Hugging Face: [modelli di AI open source](#)



INTELLIGENZA ARTIFICIALE GENERATIVA

PRINCIPALI RISCHI E PROBLEMI

Fonti:

- *ANSA, BBC, Corriere della Sera, Forbes Italia, Il Post, Il Sole 24 Ore, La Repubblica, Rai News*
- *Agenda Digitale, CorCom, DDAY.it, Geopop, Hardware Upgrade, Punto Informatico, TechCrunch, Tech Princess, Technology.org, TechRadar, Tom's Hardware, Wired Italia*
- *Facta, Valori.it*
- *16x Prompt, Digital Innovation Days, Il Disinformatico, Pluralistic, Reality Check, Siamomine*
- *IRPA, MIT Impact Bench, Privacy Network, Wikipedia*
- *GitHub, Lovense, OpenAI, YouTube*

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

PROBLEMI DELL'INTELLIGENZA ARTIFICIALE GENERATIVA

- **BIAS NEI DATI DI ADDESTRAMENTO:** pregiudizi e discriminazioni;
- **ALLUCINAZIONI:** informazioni false o fuorvianti;
- **MANIPOLAZIONE E DISINFORMAZIONE:** creazione di contenuti verosimili e/o ingannevoli;
- **PRIVACY E SICUREZZA INFORMATICA:** esposizione di dati sensibili;
- **ETICHETTATORI E SFRUTTAMENTO LAVORATIVO:** sfruttamento lavorativo e emotivo;
- **DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE:** violazione del copyright;
- **SALUTE MENTALE E EFFETTI PSICOLOGICI:** effetti sulla salute mentale;
- **IMPATTO AMBIENTALE E SOSTENIBILITÀ:** consumo energetico e inquinamento;
- **ARMİ AUTONOME:** decisioni cruciali autonome.

BIAS NEI DATI DI ADDESTRAMENTO

DEFINIZIONE

I **bias algoritmici** dell'AI sono preferenze sistematiche o discriminazioni strutturali che emergono nei **dati con cui l'AI è addestrata**. I modelli di AI imparano individuando pattern e regolarità nei dati: **se questi dati contengono pregiudizi verso una specifica categoria, l'algoritmo li apprende e li riproduce, amplificandoli.**

Approfondimento

Bias cognitivi e bias dell'AI

L'Ai è ancora addestrata con dati pieni di razzismo e sessismo

Le informazioni usate per sviluppare i sistemi di intelligenza artificiale sono infarcite di pregiudizi, che poi vengono distribuiti in tutto il mondo

All'intelligenza artificiale di Amazon non piacciono le donne scartati i cv femminili

ANTI-FRODE ED ETICA DELL'AI

L'algoritmo dei sussidi sociali discrimina e fa cadere il governo: il caso olandese

L'intelligenza artificiale non è neutrale: può imparare i pregiudizi della nostra società

Vent'anni fa, *Minority Report* aveva già capito perché la polizia predittiva avrebbe fallito

Riconoscimento facciale. Secondo uno studio la polizia del Regno Unito non rispetta gli standard minimi etici e legali.

Figura 5: Immagine creata utilizzando screenshots tratti dai seguenti articoli: [CorCom](#), [Wired](#), [Agenda Digitale](#), [IRPA](#), [Geopop](#), [Wired](#)

ALLUCINAZIONI

DEFINIZIONE

Le **allucinazioni** (dette anche confabulazioni) generate dai modelli linguistici **sono affermazioni plausibili ma false. Alcune risposte appaiono verosimili e convincenti, ma in realtà contengono informazioni errate o inventate.** Il termine deriva da una vaga analogia con le allucinazioni umane, derivate normalmente da false percezioni. Le allucinazioni dell'intelligenza artificiale tuttavia, al contrario di quelle umane, derivano da risposte costruite in modo errato, e non da un'errata percezione.

Approfondimento

Dichiarazioni di OpenAI sulle allucinazioni

Podcast RSI - Story: Perché le Tesla vedono i fantasmi?

IL PROVVEDIMENTO

Avvocato usa l'AI e cita quattro sentenze inventate, il giudice lo condanna: «Colpa grave non verificare le fonti»

ChatGpt ha un problema di diffamazione

Ha accusato un professore di diritto di un'università statunitense di molestie e un sindaco australiano di corruzione. Ma in entrambi i casi, si è inventato di sana pianta tutto

McDonald's abbandona l'intelligenza artificiale dopo gli errori comici, dal bacon sul gelato alle 260 scatole di Nuggets

Una telecamera la manda in carcere per 13 giorni: era innocente

Una donna trascorre 13 giorni in carcere dopo che una telecamera Flock ha segnalato il suo SUV vicino a un incidente mortale in Florida con tre vittime.

ChatGPT 4o ▾



How many R's are in the word strawberry

here are two "R"s in the word "strawberry."



Colla sulla pizza: Google rimuove manualmente le risposte imbarazzanti di AI Overview

Figura 6: Immagine creata utilizzando screenshots tratti dai seguenti articoli: [Il Disinformatico](#), [16x Prompt](#), [Wired](#), [Corriere della Sera](#), [Hardware Upgrade](#), [Tom's Hardware](#), [Corriere della Sera](#)




Figura 7: Screenshot di una conversazione con ChatGpt utilizzando un'immagine scattata al bar per il trentesimo compleanno di Mapo.

MANIPOLAZIONE E DISINFORMAZIONE

DEFINIZIONE

Utilizzando l'intelligenza artificiale generativa è possibile creare contenuti verosimili e/o ingannevoli, come immagini, video, audio e testi, che possono essere utilizzati per manipolare l'opinione pubblica o diffondere disinformazione.

Approfondimento

ANSA: Le manipolazioni hanno finalità politica per il 24,6% dei casi

Google's AI Answers Are Wrong Millions of Times Per Hour —
And Most People Have No Idea

Posted April 8, 2026

L'intelligenza artificiale generativa segna l'inizio di una
nuova era per la disinformazione

La polizia ha diffuso una foto degli scontri di Torino alterata
con l'IA, scatenando una vera e propria teoria del complotto

L'immagine è stata poi utilizzata sui social media per accusare l'agente aggredito di mentire

**Gli assistenti IA sono imprecisi nel dare le
notizie: il 45% delle risposte contiene
errori gravi. Lo studio della BBC**

I hacked ChatGPT and Google's AI - and
it only took 20 minutes

Figura 8: Immagine creata utilizzando screenshots tratti dai seguenti articoli: [Facta](#), [Dday.it](#), [Facta](#), [BBC](#), [Technology.org](#)

REALITY CHECK

Quiz: reale o generata artificialmente?

AI SLOP E ENSHITTIFICATION

l'**AI slop** (Sbobba) è un termine utilizzato per descrivere il fenomeno della **bas-sa qualità dei contenuti generati dall'intelligenza artificiale**, che si manifesta in particolare nei social media e nelle piattaforme di condivisione di contenuti, in quanto alle piattaforme non interessa la qualità dei contenuti, ma solo la quantità e l'engagement.

Il rischio è che l'AI slop possa portare a un **totale enshittification** delle piattaforme, con conseguenze negative per gli utenti e per la società in generale.

Approfondimento

Wired: [Andrea Daniele Signorelli - AI slop](#)

Cory Doctorow - [TikTok's enshittification](#)

PRIVACY E SICUREZZA INFORMATICA

DEFINIZIONE

Ogni **input** inserito in un chatbot può diventare parte di un'enorme **banca dati**, usata per addestrare altri modelli o **esposta**, in casi estremi, a fughe di dati o accessi non autorizzati. Ecco perché è essenziale porsi delle domande: cosa succede a ciò che scriviamo? Chi può leggerlo? Come possiamo proteggerci?

Approfondimento

Strategie pratiche per la privacy nei chatbot

**Claude usato per sviluppare armi,
sorveglianza e truffe**

**La pubblicità di ChatGPT sarà influenzata dalle nostre conversazioni
con il chatbot**

**Il clamoroso
fallimento di Builder,
la startup che invece
di un'AI aveva 700
programmatore
indiani**

Segnalazione a Character AI

Questo servizio permette agli utenti di creare dei bot
ispirati a personaggi, reali o di fantasia, con i quali è
possibile intrattenere conversazioni...

**Cina, una scuola misura l'attenzione degli studenti con il
riconoscimento facciale**

Il docente riceve in tempo reale i risultati del monitoraggio delle espressioni degli studenti, per capire se
sono attenti e se apprezzano la lezione: l'ultima frontiera del Grande Fratello cinese

Figura 9: Immagine creata utilizzando screenshots tratti dai seguenti articoli: [Punto Informatico](#), [Privacy Network](#), [Wired](#), [La Repubblica](#), [Tech Princess](#).

ETICHETTATORI E SFRUTTAMENTO LAVORATIVO

DEFINIZIONE

L'**etichettatura** dei dati richiede l'identificazione dei dati non elaborati (ad esempio immagini, file di testo, video) e quindi l'**aggiunta di una o più etichette a tali dati per specificarne il contesto** per i modelli, consentendo al modello di machine learning di fare previsioni accurate.

Approfondimento

Documentario: [In the Belly of AI](#)

Podcast RSI - Dietro le IA c'è manodopera africana sfruttata

Why Big Tech pays poor Kenyans to teach self-driving cars

Captcha if you can: how you've been training AI for years without realising it

Dietro ChatGPT c'è un esercito di addestratori sottopagati

Un'inchiesta di *Time* ha svelato che OpenAI ha affidato a un fornitore esterno il compito di visionare ed etichettare contenuti violenti per ripulire i risultati dell'algoritmo

Il lato oscuro di ChatGPT: lavoratori pagati meno di 2 dollari l'ora ed esposti alle peggiori nefandezze di Internet

Meta registra movimenti del mouse e tasti premuti dai dipendenti «per addestrare l'IA»

Gli «etichettatori», ovvero i nuovi schiavi dell'intelligenza artificiale

Figura 10: Immagine creata utilizzando screenshots tratti dai seguenti articoli: [BBC](#), [Forbes](#), [Wired](#), [TechCrunch](#), [TechRadar](#), [Dday.it](#), [Il Disinformatico](#), [Il Sole 24 Ore](#)

DIRITTO D'AUTORE E PROPRIETÀ INTELLETTUALE

DEFINIZIONE

Il **diritto d'autore** è una branca del diritto privato, che ha lo scopo di **tutelare i frutti dell'attività intellettuale di carattere creativo** (ovvero le opere devono essere nuove e originali), attraverso il riconoscimento all'autore originario (o agli autori in caso di collaborazione creativa) dell'opera di una serie di diritti di carattere sia morale, sia patrimoniale.

Approfondimento

Il diritto d'autore

Le AI hanno un grosso problema con i dati e con i copyright: cosa sta succedendo

Per allenare i suoi chatbot Anthropic ha distrutto milioni di libri

Meta sotto accusa: avrebbe usato contenuti pirata ottenuti via Torrent per allenare l'IA

DIRITTO D'AUTORE

AI e copyright, la soluzione è nelle licenze esclusive

Pokémon Go utilizzato per addestrare i droni militari? Cosa è emerso sui dati Niantic

Figura 11: Immagine creata utilizzando screenshots tratti dai seguenti articoli: [Geopop](#), [Hardware Upgrade](#), [Agenda Digitale](#), [Hardware Upgrade](#), [Il Post](#).

SALUTE MENTALE E EFFETTI PSICOLOGICI

DEFINIZIONE

L'uso eccessivo o inappropriato dell'intelligenza artificiale generativa può avere effetti negativi sulla salute mentale e sul benessere psicologico degli individui. L'interazione con chatbot o assistenti virtuali può portare a dipendenza, isolamento sociale, ansia, depressione, disturbi del sonno e altri problemi psicologici.

Approfondimento

MIT Impact Bench: AI and Mental Health

La nuova economia della solitudine

Il bisogno di ascolto in una società sempre più sola e frammentata può essere colmato dalle AI Personas?



INTELLIGENZA ARTIFICIALE

L'ascesa dei virtual influencer: cosa ci dicono sul concetto di umanità

INTELLIGENZA ASSUEFATTIVA

Algoritmi compiacenti e dipendenza emotiva: i rischi delle IA "mimetiche"

Innamorato di un chatbot, un adolescente americano si è suicidato a 14 anni. La madre fa causa all'app: «Pericolosa e non testata»

Un Gesù virtuale sta confessando i fedeli in Svizzera

Riapre Way of the Future, la chiesa che venera gli algoritmi

DIGITAL AFTERLIFE: CONTINUARE A VIVERE OLTRE LA MORTE

Serie TV: verso il futuro (episodio 7)

Figura 12: Immagine creata utilizzando screenshots tratti dai seguenti articoli: [Siamomine](#), [Agenda Digitale](#), [Wired](#), [Corriere della Sera](#), [Ansa](#), [Digital Innovation Days](#), [Agenda Digitale](#), [Lovense: interactive AI robot sex doll](#)

IMPATTO AMBIENTALE E SOSTENIBILITÀ

DEFINIZIONE

L'addestramento e l'utilizzo di modelli di intelligenza artificiale generativa richiedono **grandi quantità di energia e risorse computazionali**, che possono avere un impatto significativo sull'ambiente. L'uso intensivo di data center e server per l'elaborazione dei dati può contribuire all'aumento delle emissioni di gas serra e al consumo di risorse naturali.



Figura 13: Approfondimento [Rai News: L'impatto ambientale dell'AI](#)

ARMI AUTONOME

DEFINIZIONE

Le **armi autonome** sono sistemi d'arma che, una volta attivati, possono **selezionare e ingaggiare obiettivi senza intervento umano**. L'uso di intelligenza artificiale generativa in ambito militare solleva questioni etiche e legali, in quanto le decisioni cruciali vengono prese da algoritmi, senza la supervisione umana diretta. Ciò può portare a conseguenze imprevedibili e potenzialmente pericolose, sollevando dibattiti sulla responsabilità e la regolamentazione di tali tecnologie.

Approfondimento

NAZA: Sistemi IA israeliani per uccidere palestinesi



Figura 14: Immagine di copertina del dossier di Valori.it: **L'intelligenza artificiale va al fronte**

INTELLIGENZA ARTIFICIALE GENERATIVA

BEST PRACTICES PER L'USO CONSAPEVOLE

Fonti:

- *DAIR.AI: Prompting Guide*
- *IBM: Prompt Engineering*
- *Claude: Best Practices for Prompt Engineering*
- *Google: What is Prompt Engineering*

Dwar Ev abbassò la leva. Si udì un formidabile ronzio che concentrava tutta la potenza, tutta l'energia di novantasei miliardi di pianeti. Grappoli di luci multicolori lampeggiarono sull'immenso quadro, poi, una dopo l'altra, si attenuarono.

Dwar Ev fece un passo indietro e trasse un profondo respiro.

«L'onore di porre la prima domanda spetta a te, Dwar Reyn.»

«Grazie», disse Dwar Reyn. «Sarà una domanda cui nessuna macchina cibernetica ha potuto, da sola, rispondere.»

Tornò a voltarsi verso la macchina.

«C'è Dio?»

L'immensa voce rispose senza esitazione, senza il minimo crepitio di valvole o condensatori.

«Sì: *adesso*, Dio c'è.»

Il terrore sconvolse la faccia di Dwar Ev, che si lanciò verso il quadro di comando.

Un fulmine sceso dal cielo senza nubi lo incenerì, e fuse la leva inchiodandola per sempre al suo posto.

(da *L'ora di fantascienza*, trad. di C. Fruttero, Einaudi, Torino, 1982)

BEST PRACTICES

USA L'AI PER IMPARARE, NON USARE L'AI AL POSTO DI IMPARARE




Figura 16: creata con Gemini

AUTOPILOTA

L'AI fa il lavoro al tuo posto:

- Risolve i problemi di matematica
- Scrive i tuoi temi

Risultato: spegne il tuo cervello, non impari nulla.

CO-PILOTA

l'AI lavora con te:

- Ti spiega come approcciare un problema
- Critica e migliora le tue bozze

Risultato: amplifica le tue capacità, impari più velocemente.

TECNICA 1: DAI ALL'AI UN'IDENTITÀ

Senza contesto, l'AI è generica e superficiale. **Forniscile un'identità e un ruolo specifico**, così da ottenere risposte più pertinenti e approfondite.

Esempio di prompt

RUOLO: Sei un professore di informatica con molti anni di esperienza, specializzato in intelligenza artificiale.

TONO: Usa un linguaggio semplice e chiaro, adatto a studenti di scuola superiore.

OBIETTIVO: Crea delle slides per una lezione di 1 ora sull'AI generativa con esempi pratici e comprensibili.

Spoiler

Queste slides non sono state generate da un'intelligenza artificiale

TECNICA 1: DAI ALL'AI UN'IDENTITÀ

Senza contesto, l'AI è generica e superficiale. **Forniscile un'identità e un ruolo specifico**, così da ottenere risposte più pertinenti e approfondite.

Esempio di prompt

RUOLO: Sei un professore di informatica con molti anni di esperienza, specializzato in intelligenza artificiale.

TONO: Usa un linguaggio semplice e chiaro, adatto a studenti di scuola superiore.

OBIETTIVO: Crea delle slides per una lezione di 1 ora sull'AI generativa con esempi pratici e comprensibili.

Spoiler

Queste slides non sono state generate da un'intelligenza artificiale

TECNICA 2: MOSTRA, NON LIMITARTI A CHIEDERE

l'AI impara dai pattern. Invece di limitarti a formulare domande, **mostra all'AI esempi concreti di ciò che desideri ottenere**, descrivendo in dettaglio come vuoi che appaia il risultato finale.

Esempio di prompt

Crea delle slides per una lezione di 1 ora sull'AI generativa con esempi pratici e comprensibili.

Ecco un esempio di come vorrei che fossero strutturate tutte le slides:

- Titolo della slide in alto con sfondo giallo
- Riquadro centrale con titolo in rosso e contenuto in nero
- Sfondo bianco con numeri di pagina in basso a destra
- Didascalia inserita in basso a sinistra del riquadro con font piccolo che cerca senza successo di essere simpatica

Spoiler

Ripetizione: queste slides non sono state generate da un'intelligenza artificiale

TECNICA 2: MOSTRA, NON LIMITARTI A CHIEDERE

l'AI impara dai pattern. Invece di limitarti a formulare domande, **mostra all'AI esempi concreti di ciò che desideri ottenere**, descrivendo in dettaglio come vuoi che appaia il risultato finale.

Esempio di prompt

Crea delle slides per una lezione di 1 ora sull'AI generativa con esempi pratici e comprensibili.

Ecco un esempio di come vorrei che fossero strutturate tutte le slides:

- Titolo della slide in alto con sfondo giallo
- Riquadro centrale con titolo in rosso e contenuto in nero
- Sfondo bianco con numeri di pagina in basso a destra
- Didascalia inserita in basso a sinistra del riquadro con font piccolo che cerca senza successo di essere simpatica

Spoiler

Ripetizione: queste slides non sono state generate da un'intelligenza artificiale

TECNICA 3: CHAIN OF THOUGHT (CATENA DI PENSIERO)

L'AI è più efficace quando ragiona passo dopo passo. **Chiedile di spiegare il suo ragionamento**, così da ottenere risposte più accurate e approfondite. Se chiedi solo la risposta finale, spesso cerca di indovinare senza spiegare il processo logico e sbaglia.




Figura 17: creata con Gemini

SYCOPHANCY (compiacenza)

PROBLEMA: L'AI È COMPIACENTE

Quando **chiediamo un consiglio** all'intelligenza artificiale su un dubbio o una decisione da prendere, **la risposta spesso ci soddisfa al primo colpo**. Il motivo è semplice: **l'IA tende a darci ragione**, assecondando le nostre premesse e facendoci da cassa di risonanza.

Uno dei **pericoli più grandi** non è la menzogna palese, ma la **conferma di una nostra verità parziale che rimuove il dubbio su noi stessi**. Se l'IA si limita a dirci ciò che vogliamo sentire, **annulla la nostra capacità critica**.

Per trasformare l'IA da uno strumento di validazione a un reale alleato di riflessione, serve **cambiare l'approccio con cui le parliamo**.

Fonte

Matteo Flora: [Ciao Internet](#).

TECNICA 4: STRESS-TEST

- **Inverti l'obiettivo: cercare la smentita, non la conferma:** chiedile di trovare argomenti contro la tua tesi.
- **Forza l'IA a cambiare prospettiva:** chiedile di assumere il ruolo di un avversario, di un critico o di un esperto con opinioni opposte alle tue e di riconsiderare la questione da quel punto di vista.
- **Usa l'IA come sparring partner, non come oracolo:** L'obiettivo non è farsi dire cosa fare, ma farsi fare le domande che non ci stiamo ponendo.

L'IA diventa uno strumento di crescita personale e professionale non quando ci dà risposte rassicuranti, ma quando viene forzata a smontare le nostre certezze.

TECNICA 4: STRESS-TEST

- **Inverti l'obiettivo: cercare la smentita, non la conferma:** chiedile di trovare argomenti contro la tua tesi.
- **Forza l'IA a cambiare prospettiva:** chiedile di assumere il ruolo di un avversario, di un critico o di un esperto con opinioni opposte alle tue e di riconsiderare la questione da quel punto di vista.
- **Usa l'IA come sparring partner, non come oracolo:** L'obiettivo non è farsi dire cosa fare, ma farsi fare le domande che non ci stiamo ponendo.

L'IA diventa uno strumento di crescita personale e professionale non quando ci dà risposte rassicuranti, ma quando viene forzata a smontare le nostre certezze.


TECNICA 4: STRESS-TEST

- **Inverti l'obiettivo: cercare la smentita, non la conferma:** chiedile di trovare argomenti contro la tua tesi.
- **Forza l'IA a cambiare prospettiva:** chiedile di assumere il ruolo di un avversario, di un critico o di un esperto con opinioni opposte alle tue e di riconsiderare la questione da quel punto di vista.
- **Usa l'IA come sparring partner, non come oracolo:** L'obiettivo non è farsi dire cosa fare, ma farsi fare le domande che non ci stiamo ponendo.

L'IA diventa uno strumento di crescita personale e professionale non quando ci dà risposte rassicuranti, ma quando viene forzata a smontare le nostre certezze.

TECNICA 5: LA VALVOLA DI SICUREZZA

I modelli linguistici vogliono accontentarci a tutti i costi. Se non sanno qualcosa, la inventano. **Devi autorizzarli a non sapere per evitare il più possibile le allucinazioni.**



Analizza questi appunti storici. Quali date mancano per completare la linea del tempo?

[VINCOLO CRITICO]: Se i miei appunti sono insufficienti per trarre una conclusione, dimmi chiaramente "Non ho abbastanza dati" invece di speculare o inventare date storiche.

EI IA, RIASSUMI.

IMPARARE VS BARARE

Materia	L'Autopilota (Barare) ✗	Il Co-Pilota (Imparare) ✓
Lettere	Scrivi un tema su Leopardi per me.	Ho scritto questa bozza su Leopardi. Fai il ruolo di un critico e indicami dove le mie argomentazioni sono deboli. Non riscriverlo.
Matematica	Risolvi l'equazione: $3x + 4 = 19$.	Non riesco a capire come isolare la 'x'. Spiegami il primo passaggio teorico senza risolverla.
Inglese	Traduci questo testo in inglese.	Agisci come un madrelingua. Facciamo una conversazione in inglese sul mio hobby. Correggi i miei errori di grammatica dopo ogni mia risposta.

Figura 19: creata con Gemini



Zone di Pericolo: Come NON Usare l'AI

1

Outsourcing del Pensiero

Copiare un saggio generato dall'AI non è solo plagio; impedisce la creazione di nuove connessioni neurali. Stai letteralmente bloccando il tuo sviluppo cognitivo.

2

Fiducia Cieca

Non usare MAI l'AI come fonte primaria di fatti o per fare ricerca bibliografica senza verificare i testi originali su fonti autorevoli.

3

Condivisione di Dati Privati

Non inserire MAI dati sensibili, password, o informazioni private dei tuoi compagni o della scuola nei prompt. L'AI non è un diario segreto.

Figura 20: creata con Gemini

Prima di premere 'Invio' su qualsiasi prompt, verifica questi tre elementi:

	È specifico? (Ho definito un ruolo, fornito contesto, esempi e vincoli chiari?)
	Mi aiuta a imparare? (Sto mantenendo il controllo del lavoro o sto chiedendo alla macchina di pensare al posto mio?)
	Posso verificarlo? (Ho le competenze o i libri di testo necessari per smascherare eventuali allucinazioni in questa risposta?)

Figura 21: creata con **Gemini**